PROJECT 2

Model B6 Investigation & Evidence-Grounded Agents

訓練模型、追查異常，讓 AI 讀取實驗結果

MODEL B6 / AGNO / DIAGNOSTICS

巫承志 / 113033225 / 動機28

FINAL REPORT · 2026.10.09

課程完成狀態

課程要求已完成，新增功能也已實測

課程要求	完成內容與紀錄	目前狀態
Step 5 訓練	60 epochs；保留 Final／Best 模型	CONFIRMED
Step 6 驗證	美國／台灣 × Final／Best	CONFIRMED
Agno / agent.py	獨立環境、相容處理、Baseline 實測	CONFIRMED
5-Level / Do New	架構分級分析、Evidence Agent	CONFIRMED

新增功能：本次實測與內容核對

功能	執行	回答內容
Evidence Agent	PASS	已審核
Vision Agent	PASS	單張已審核
Diagnosis／Unified	PASS	已核對並修正

我完成的工作，以及怎麼追查模型問題

課程要求

模型訓練、四組驗證
Agent 與 Do New

改善

把資料配對、環境
和結果檔案檢查好

自行設計的調查

用對照實驗追查問題
再測試修復方法

模型調查如何一步步縮小問題？

01 發現問題	02 檢查顯示	03 只換一項	04 測試修復	05 做出決策
模型直接輸出 就已出現鋸齒	資料配對一致 投影和參考相符	換影像差很小 換 state 差很多	Depthwise／ 混合 state 短訓練	未達續訓條件 不做長時間訓練
14–15 頁	15–16 頁	17–23 頁	24–27 頁	28 頁

CONFIRMED | 調查步驟與結果都有紀錄。真正原因、有效修復與駕駛品質，仍未證實。

系統分工

模型訓練與 Agent 分開跑，共用實驗資料

沿用 Project 1

OpenPilot / dataB6 / dataC

沿用的資料只讀取，不改寫

Model B6

TensorFlow 2.13.1
Python 3.8 Docker

→

實驗結果

JSON／檔案清單
實際驗證圖片

→

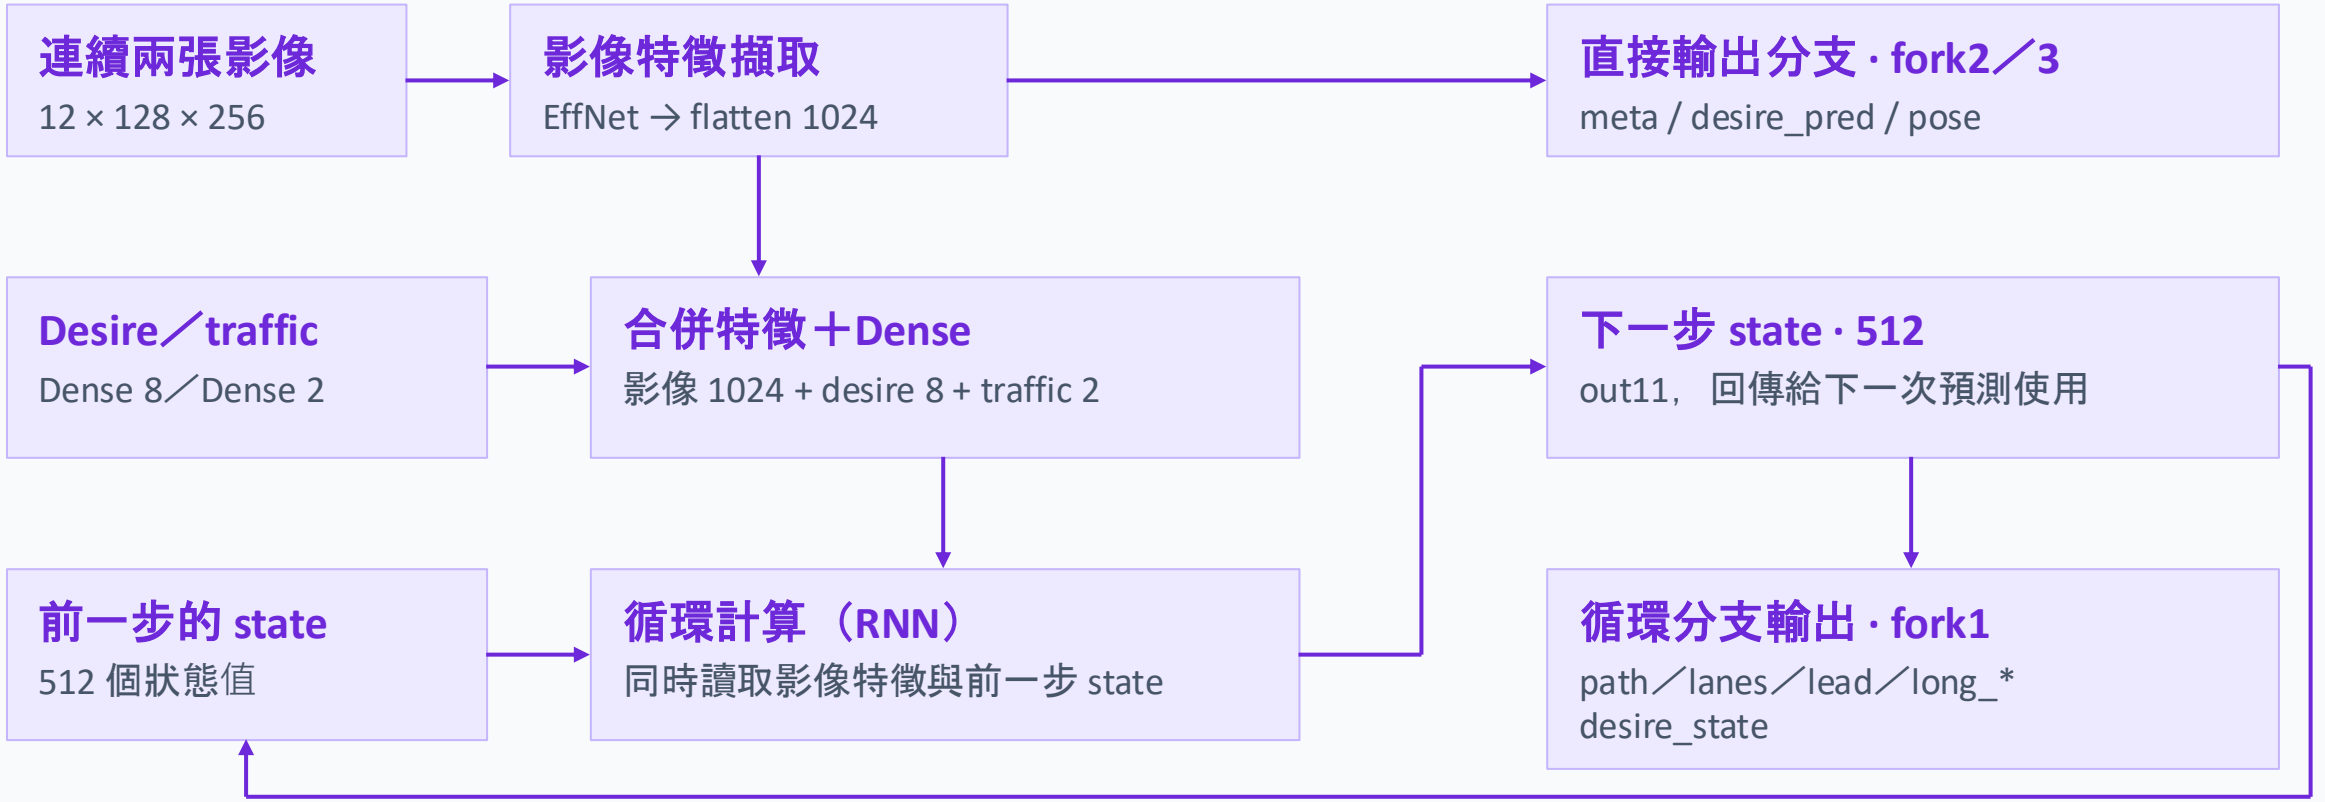
AI Agent

Agno 3.1.1
Python 3.11 venv

Agent 只讀取模型結果，協助分析，不會改動模型。

Project 1 只提供既有環境。本報告呈現 Project 2 的工作，原始資料、處理後資料與輸出分開存放。

Model B6 讀入哪些資料，怎麼產生輸出



state 把前一步資訊帶到下一步；外側箭頭是回饋流程。12 組輸出共 2383 個值。

依 get_model()／RNN() 繪製。Gate 內含可訓練的 Dense，因此不直接套用標準 GRU 公式。

訓練資料與 Teacher forcing（教師引導）

資料來源	Teacher 資料列數	用途
USA --33	1198	訓練
USA --37	1199	訓練
USA --32	1199	驗證
supercombo079.keras	每列 2383 個值	訓練目標

連續影像 (i,i+1) 對應 Teacher 第 i 列輸出；state 讀取 Teacher 前一列的 512 個值，片段起點設為 0。
模型學的是教授的預測，不是人工標註的道路真值。

我做的工程改善

把資料配對好，換影片時重設 state

可能出錯的地方	我的處理方式	怎麼檢查
影像配到錯的資料	核對影片與資料列都相同	資料配對測試
換影片後還沿用舊 state	每段影片起點把 state 設為 0	檢查實際影片切換
重新訓練與接續訓練混淆	執行時明確選擇起始方式	流程測試／資料試跑

先前已通過 7 項修正測試＋13 項實際流程測試，並試跑 599 批資料。

用 val_loss 選出 Best 模型。修正在我的外層程式，保留教授的模型與 loss 計算。

開始正式訓練前，先通過五個檢查

環境

掛載／分組
檔案指紋

→

訓練目標

形狀／有效值
檔案指紋

→

試跑

資料連線
影片切換

→

訓練

每次新編號

→

重新載入

用新程序檢查

資料或結果檔案對不上，就停止執行。

原始資料與教授程式只讀取。處理後資料先寫入暫存區，完成後一次發布並留下完成標記；既有結果不覆蓋。
接續訓練會另開一段，不會恢復 optimizer／scheduler 的內部狀態。

STEP 5 · 訓練已完成

完成 60 epochs 的基準訓練

60

已完成訓練輪數（epochs）

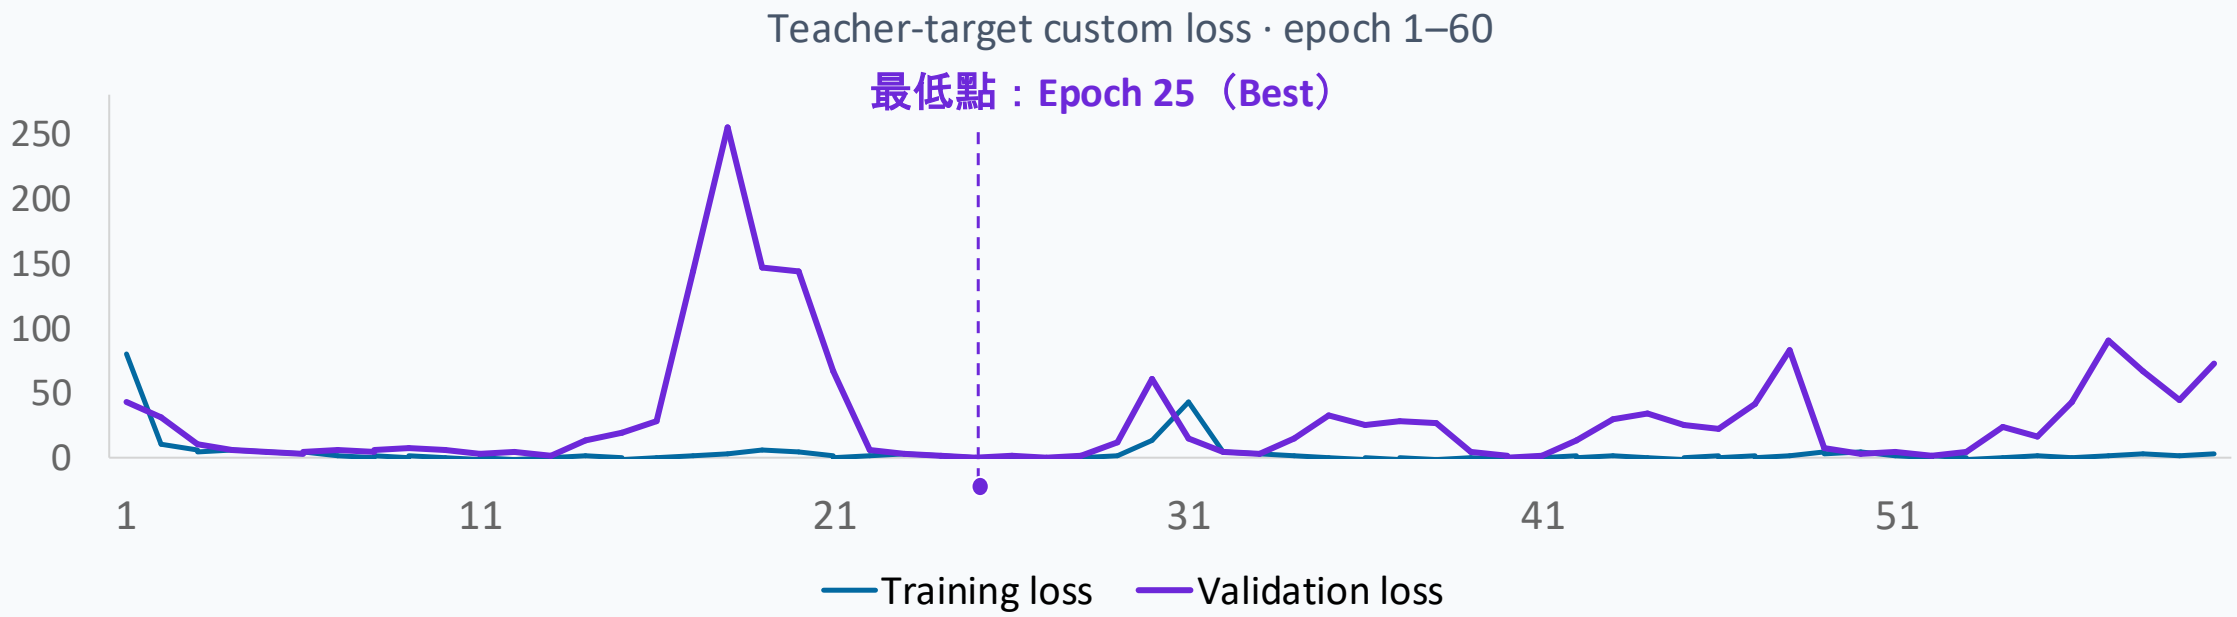
1200 / 600
訓練／驗證步數

13,039,435
模型參數數量

289.48 s
從建立模型到存好 Final 模型

每 epoch 訓練 20 步、驗證 10 步，每批 2 筆；60 epochs 不等於把整份資料讀過 60 次。
Loss 衡量模型與教授目標的差距；權重：path／左／右各 0.3，全輸出 0.1。
紀錄：p25-baseline-20261005。Adam，cosine 1e-3 至 5e-4。

驗證 loss 起伏很大，最後的模型不是最佳模型



第 25 epoch 的驗證 loss 最低：0.5254；最後一輪是 71.7146。

最後一輪訓練 loss 為 3.2041，上圖保留全部 60 epochs。

評估 A：每 epoch 驗證 10 步、每批 2 筆，每輪讀到的片段不同。

沿用 教授前一步 state 與原 loss，用每輪平均選 Best；與第 11／32 頁的算法不同。

LIKELY / SUGGESTED | 結果可能反映訓練不穩定；只憑這段驗證影片，還不能確定是過度擬合。

STEP 5 · 比較模型版本

用同樣 120 筆資料， Final loss 是 Best 的 6.48 倍

BEST · 第 25 EPOCH

12.2088

B6BW.hdf5

FINAL · 第 60 EPOCH

79.1267

B6.keras

相同評估條件下， Final loss 約為 Best 的 6.48 倍

評估 B：固定同一批 120 筆驗證資料，教授 state 也相同

本頁用 120 筆驗證資料的平均 loss 比較 Best／Final，沒有另外建立獨立測試集。
第 10 頁算每輪平均，第 32 頁算另一組 18 筆的中位數，三者不能直接互比。
Final 較差已確認；訓練不穩定仍是推測（LIKELY / SUGGESTED），尚不能確認過度擬合。

Step 6：把影片送進模型，再檢查結果

讀取影片

逐格解碼
計算幀數

→

兩張 YUV

沿用教授的
轉換方式

→

四個輸入

回饋自己的
state

→

模型輸出

2383 個原始值

→

顯示結果

JSON＋四格驗
證圖

美國與台灣影片，分別使用課程指定的投影設定。

美國右車道偏移採教材的 -0.5，取代 parser 的 -0.1；台灣的路徑、車道各自校正。
使用 stable softplus，避免 exp 溢位；驗證 traffic=[0,0]、訓練為 [1,0]，解讀時保留這項差異。

四組影片都跑完，再看輸出是否合理

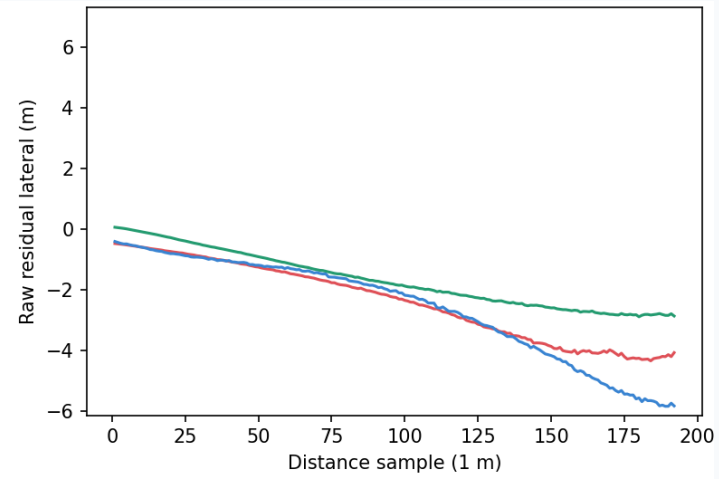
影片／模型	預測筆數	近端路徑變化均值 m	車道寬度≤0 的幀數
USA final	1199	1.0903	1006
USA best	1199	0.00460	0
Taiwan final	1201	0.9993	943
Taiwan best	1201	0.00460	0

四組輸出都沒有 NaN／Inf，流程已跑完；但 Final 的車道寬度≤0 幀數，明顯多於 Best。

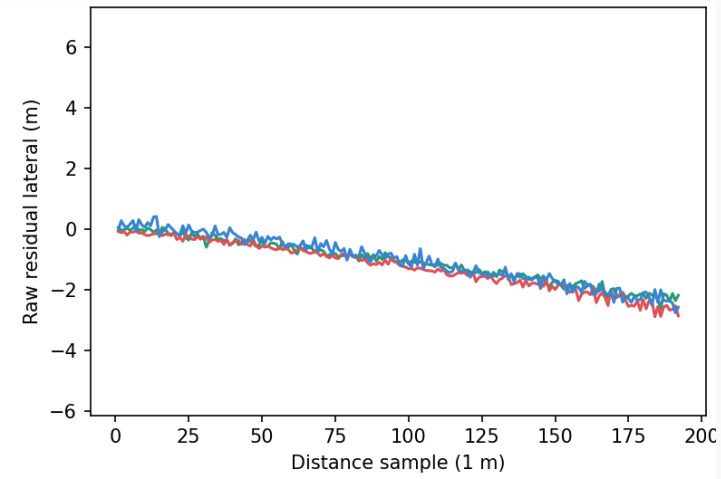
同一張影像，我的原始輸出已有鋸齒

三圖使用相同 Y 軸。這裡看曲線形狀與位置，還不能判定預測是否準確。

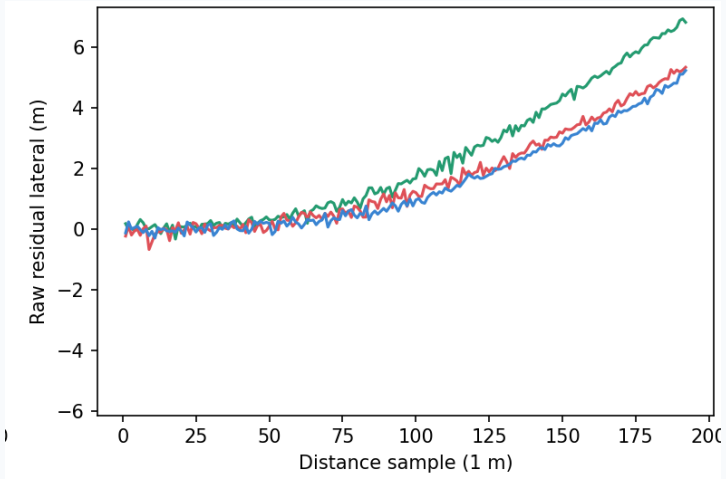
TEACHER · supercombo079



B6 BEST



B6 FINAL

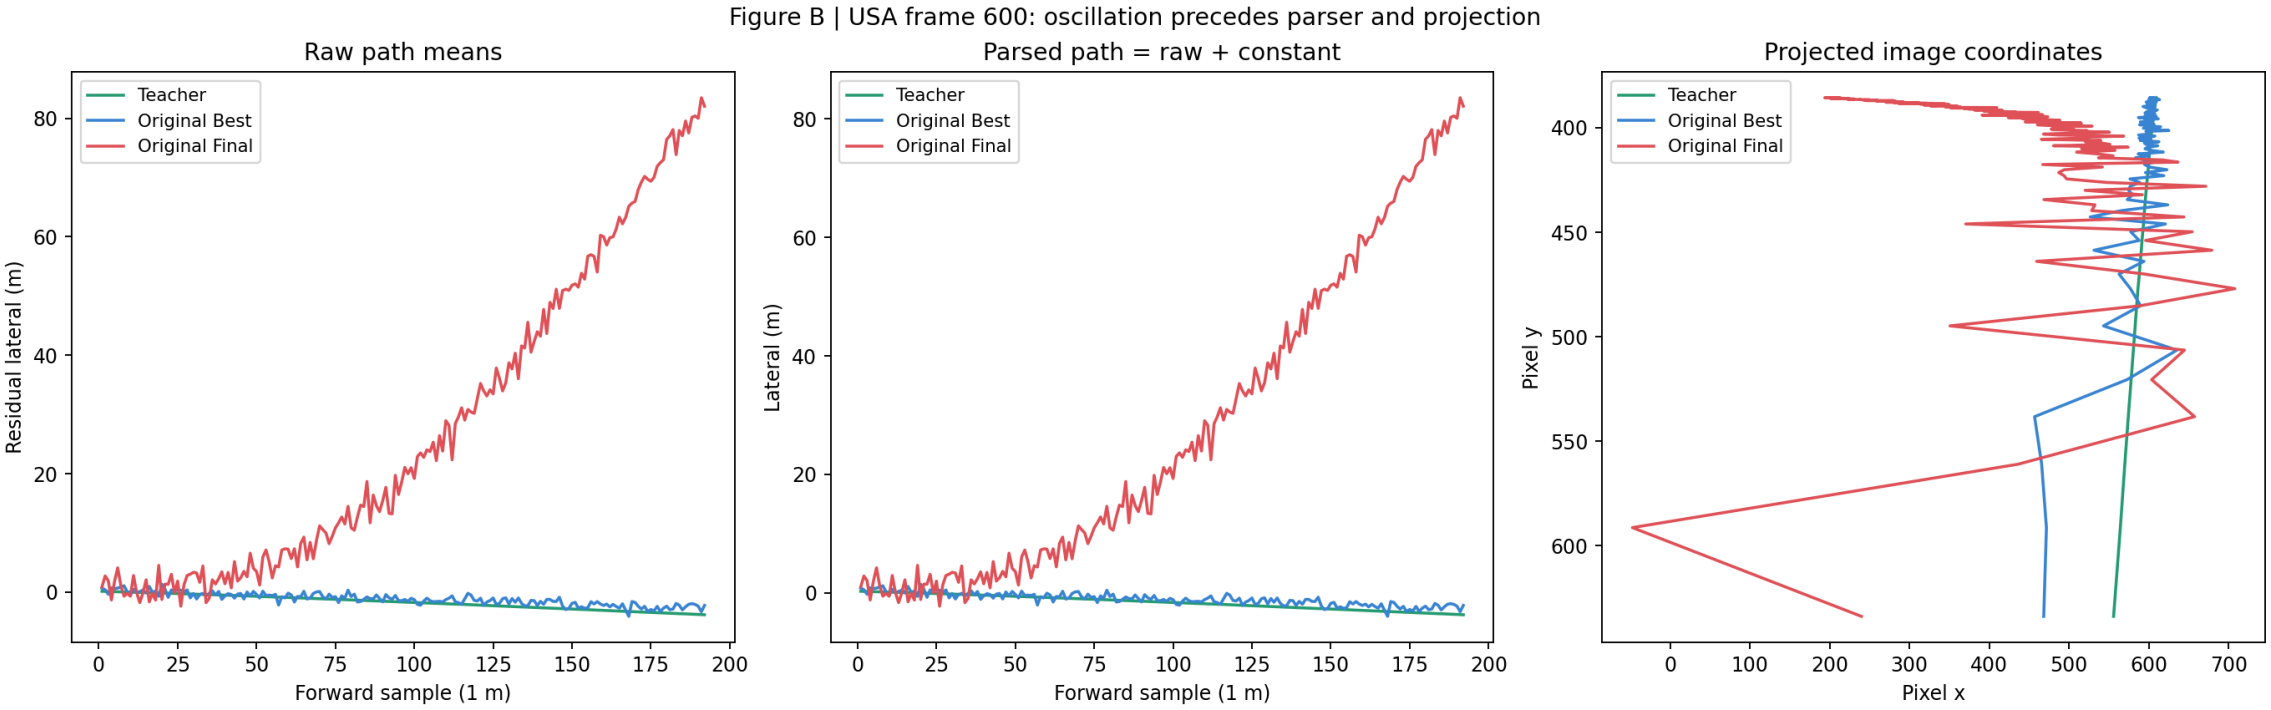




用同一張影像，也固定 state 與 traffic

台灣第 601 幀；使用教授前一步 state、traffic=[1,0]。
路徑與車道線在投影前就不平滑，異常不是疊到畫面上才出現。

曲線在投影到畫面前，就已經不正常



模型直接輸出（Raw）

還沒解析，就已出現鋸齒。

解析後（Parsed）

加上固定偏移，異常仍在。

投影到畫面（Projected）

把曲線位置換成像素座標。

影像真的不同，資料配對與數值範圍也查過了

先確認：實驗確實換了不同影像

不同影像

美國／台灣對照影像的平均像素差（MAE）為 9.312–19.002。

配對一致

3 組美國影片解碼影像，與訓練用 yuv.h5 完全相同（差異 = 0）。

數值範圍一致

訓練與推論都沒有除以 255；訓練第一批的值落在 35–204。

只換一項輸入來比較

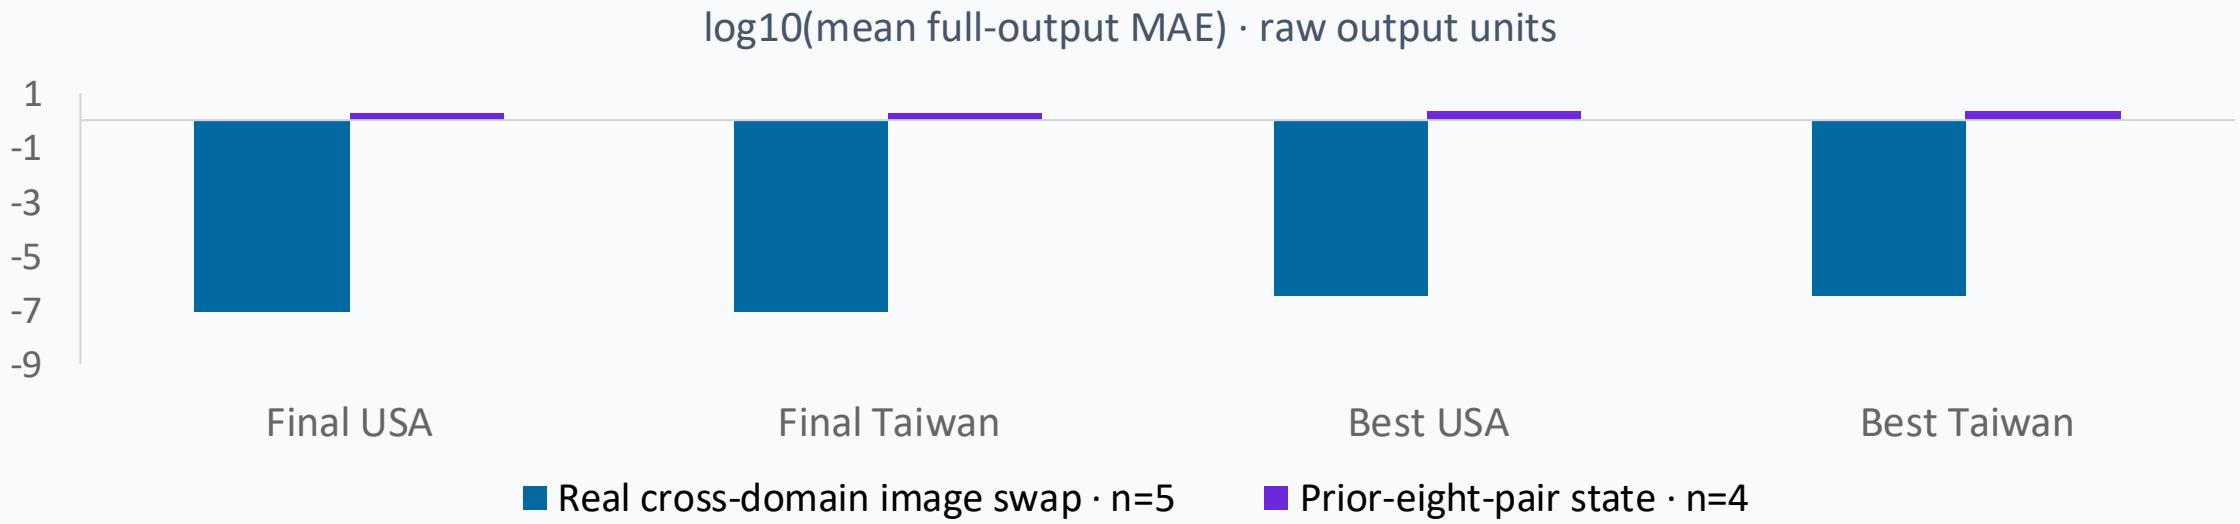
只換影像，輸出幾乎不變；換 state，差異就很大

換影像／輸出幾乎不變

MAE ≈ 1e-7

換前一步 state／輸出明顯改變

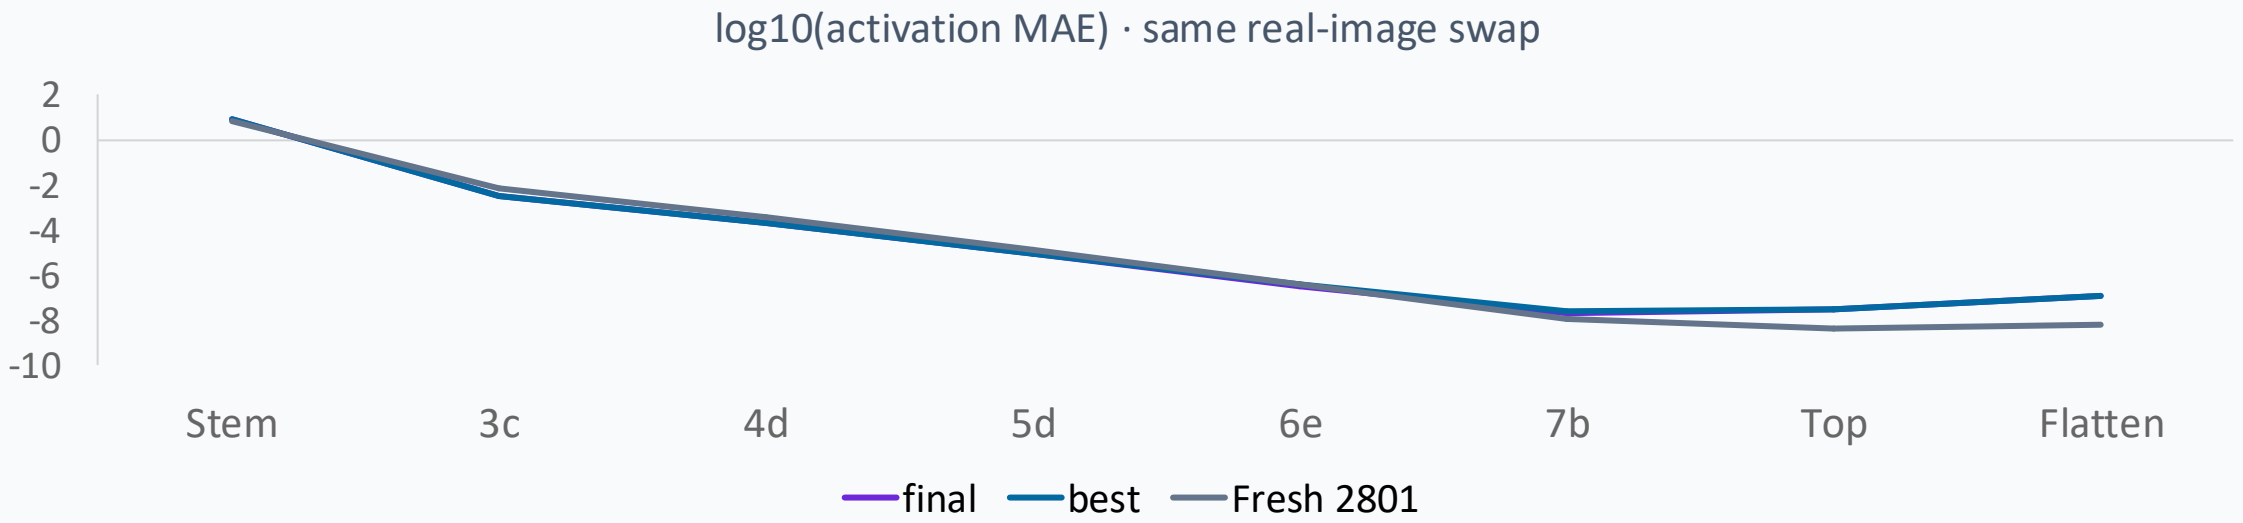
MAE 1.868–2.046（約 1e0）



比較完整原始輸出的平均絕對差（MAE），圖用 log10 刻度。每組分別測 5 筆影像替換、4 筆前 8 組影像推算的 state 替換。
每次只改一項，其餘輸入與權重固定；兩項實驗樣本數不同，不能當作普遍的因果效果。

不同影像經過 Encoder 後，反應差異整體縮小

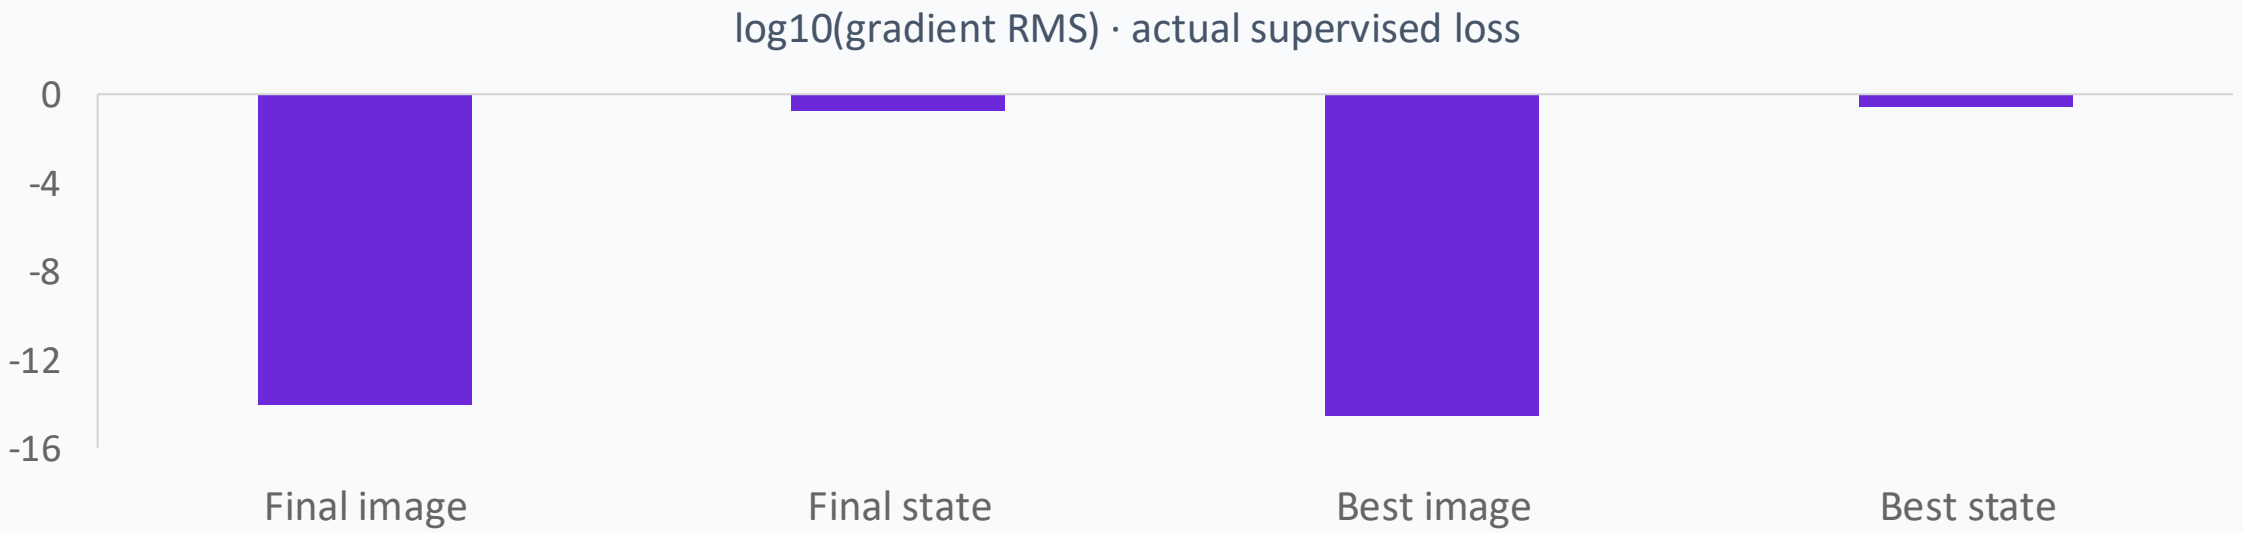
兩張已測影像，越到特徵擷取後段，內部數值的差異整體越小。



Final 最後一層的差異 MAE≈1.076e-7，平均內部數值大小≈2.824。
這可能和換影像時反應很小有關，但還不能確認是唯一原因。

微調影像與 state 時，loss 的反應差很多

影像梯度約 1e-15–1e-14，state 約 1e-1，相差約 13–14 個數量級。

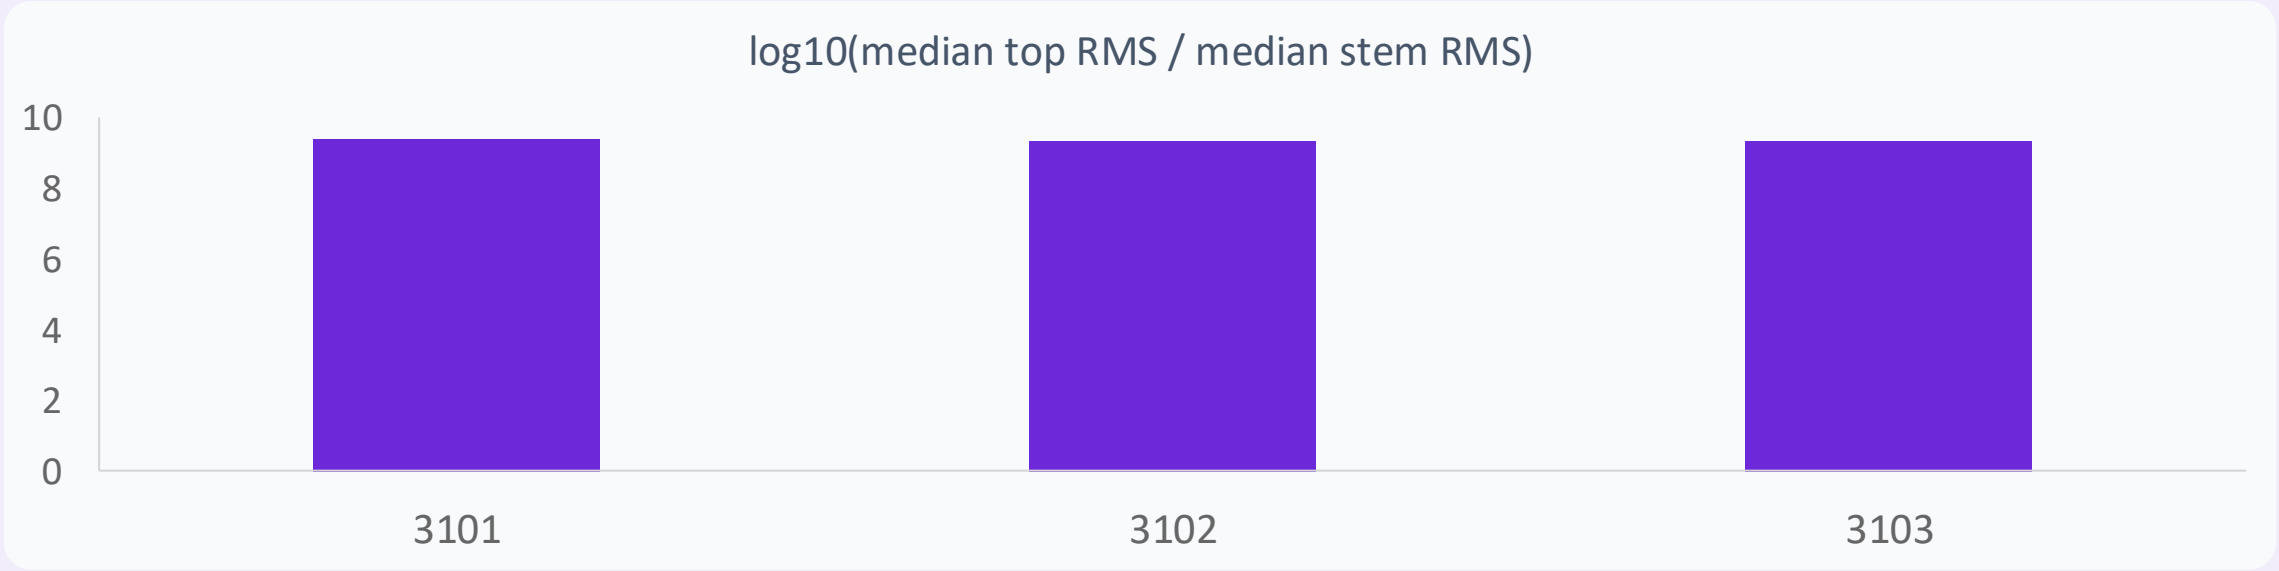


梯度衡量輸入微調時 loss 的變化。圖是 18 筆原始條件下的梯度 RMS 中位數，使用 log10 刻度。
沿用原 loss 與訓練目標；影像和 state 的單位不同，不能直接把倍數當作因果影響。

Final 影像／state 梯度 RMS：9.775e-15／0.1907；Best：2.580e-15／0.2903。
這些點的影像梯度極小但不是 0，也不能推論所有影像都不影響模型。

還沒開始訓練，梯度往前傳就已大幅變小

這是訓練造成的嗎？3 個尚未訓練的對照模型，也出現相同現象。



3 個隨機種子，各測同一批 18 筆快取資料，共 54 筆紀錄；訓練更新次數為 0。
以梯度 RMS 中位數比較，Top 比 stem 大約 9.30–9.40 個數量級；不是逐筆比值的平均。

現象在訓練前就存在，但還不能確定是起始權重的設定造成。
接著看另一個可能影響結果的輸入：state 從哪裡來？

檢查 STATE 的來源

訓練讀 Teacher state，推論卻回饋自己的 state

訓練時

Teacher s[t−1] ⟶ Student ＋連續兩張影像

自己連續預測時

Student s[t−1] ⟶ Student ＋連續兩張影像

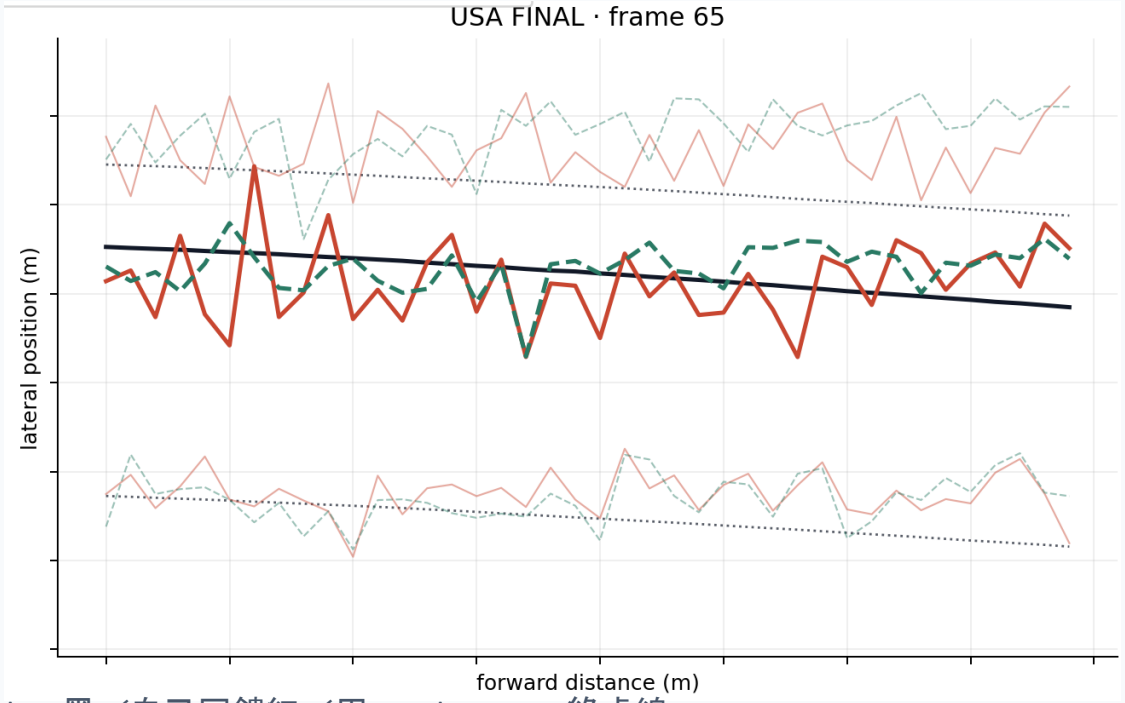


把自己輸出的 512 個 state 值，送回下一步

推測：兩種來源的 state 分布不同，可能影響連續預測。
Teacher s[t−1] 只含過去資訊，沒有讀到未來；是否為唯一原因，尚未驗證

換成 Teacher 的 state， 整段曲線就明顯不同

USA Final · frame 65



Teacher 黑／自己回饋紅／用 Teacher state 綠虛線

整段車道寬度≤0 幀數 · 0–40 m

USA · 1199 frames

1006 → **0**

Taiwan · 1201 frames

943 → **0**

回饋自己的 state　　用 Teacher state

觀察：只換 state 的輸入方式， 兩段影片的計數就差很多（traffic=[0,0]）。
限制：實際使用時沒有 Teacher state；計數為 0 也不代表平滑、準確或安全。
來源分布不同仍是假設；後續混合 state 訓練也沒達到續訓條件（26–27 頁）。

只換一次 Teacher state，效果取決於時機

實驗 A：台灣第 1 幀換入 Teacher state，整段車道寬度≤0 幀數反而增加

943

維持原本 state

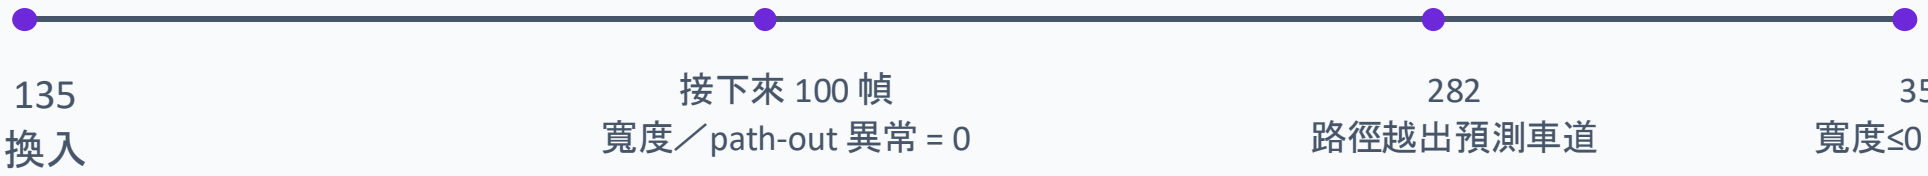
→

1006

第 1 幀換入後

多 63 幀

實驗 B：第 135 幀換入，短暫改善後又出現異常



換入時機不同，效果也不同，尚未找到持續恢復的方法。上圖為台灣；美國在第 245／313 幀再出現路徑／寬度異常。

改 Depthwise 起始權重，5 項檢查只通過 2 項

兩組都訓練 8 epochs ×20 步 ×每批 2 筆，只改 depthwise 起始權重的設定；用固定 120 筆驗證。

繼續長訓練的條件	原設定 → 修改後	結果
總 loss 降低	12.2589 →12.2391	**通過（−0.16%）**
路徑／車道誤差 MSE 降低	23.9895／23.4174 →23.9954／23.4308	**未通過**
曲線更平滑（二階差分降低）	0.4223 →0.4909	**未通過**
車道線交錯次數不增加	已測片段：0 →0	**通過**
換影像時，路徑反應變大	1.47e−7 →4.06e−8	**未通過**

不繼續長訓練：3 項條件沒通過，不能只看總 loss 有降低。

CONFIRMED | 兩組短訓練都完成，但還沒證明能修好曲線，因此沒有繼續長訓練。

混入 Best 模型的 state，能讓連續預測更穩嗎？

Teacher s[t−1]

固定 Best 模型的 s[t−1]

每段影片從頭跑，先存好 state

→

每筆選一種來源

選 Best 的機率
q＝0／25／50%

→

相同 Student

Teacher 訓練目標
保持不變

E0 0%　　E1 25%　　E2 50%

都訓練 8 epochs ×20 步 ×每批 2 筆；起始權重、資料、Adam 與 loss 相同

只用過去的 state，且 Best 模型先固定、不隨訓練更新；不測動態快取、BPTT 或自動調整混合比例

混合 state 後異常更多，因此不繼續長訓練

相同訓練量／同批評估	E0 · 0%	E1 · 25%	E2 · 50%
驗證 loss	14.4614	16.3557	17.5898
美國 path-out／1199 幀	0	14	412
台灣 path-out／1201 幀	2	164	731

E1／E2 在兩段影片的 path-out 都增加，state 大小（RMS）也高於 E0。

State 大小 RMS（E0／E1／E2）：USA 8.237／16.280／13.075；Taiwan 8.259／16.286／13.066。

E0 美國的失敗計數已經是 0，無法證明原訂「非零失敗計數再降 ≥20%」。
因此不能算通過，也沒有事後放寬標準；完整條件與數值保留在備註及原始決策紀錄。

Path-out 指預測路徑超出「預測車道」，不是實車偏離道路；結論只涵蓋本次短訓練。

平均誤差變小，不代表連續預測更穩

E2 與 E0 比較：同一組美國資料，同時看單次誤差與相鄰預測的變化。

−12.8%

路徑誤差 MAE 降低

0.4702 →0.4102 m

平均來看，預測更接近 Teacher。

約 22×

相鄰兩幀的路徑變化變大

0.01330 →0.29306 m

連續預測的跳動更大，穩定性變差。

決策：路徑形狀、state、跨幀變化與模仿誤差都要過關，這個版本不繼續長訓練。

E2 在台灣的路徑 MAE 也沒改善。結論只涵蓋固定 Best state 的做法，其他方法仍未測試。

Model B6：查到了什麼，還有哪些問題沒解

發現 鋸齒在投影前就有；換影像差很小，換 state 的方式則差很多。

檢驗 Depthwise 與混合 state 都做過短訓練，但都未達到續訓條件。

待解 真正原因、能否修好模型與駕駛品質，仍未證實。

推測｜影像修正作用太弱，加上連續預測不穩，可能一起影響恢復。

實驗資料越來越多，接著讓 AI Agent 協助讀資料，並保留每項判斷的來源。

在獨立 Python 環境中跑完教授的 Agent 範例

執行環境	Python 3.11.4 / Agno 3.1.1 / Google GenAI 2.28.0
教授範例	程式有 6 個 Agent 定義，實際只執行旅行規劃這一個任務
實際執行結果	呼叫 think／analyze、產生完整回答，最後回到終端機

CONFIRMED｜已核對使用者提供的完整執行紀錄。旅行內容只是範例，沒有查證或預訂。
學生程式預設 gemini-3.8-flash，可用 GEMINI_MODEL_ID 更換；這是目前程式設定。

調整舊版參數，讓教授範例順利執行

教授原始程式

agent_id / add_datetime_to_instructions
舊 YFinance keyword / show_tool_calls

我的相容處理

id / add_datetime_to_context
enable_* 財經參數／移除顯示參數

用 AST 讀出 Agent 定義與實際任務，避免一匯入範例就呼叫 API。

確認共有 6 個 Agent 定義、1 個實際任務，保留教授原檔。離線測試檢查是否能建立 Agent、工具是否有註冊。
相容處理只解決 API 用法差異，不會讓 Agent 自動升到更高架構等級。

依五層架構來看，目前主要做到 Level 1

Level／需要的能力	本專案	怎麼判斷
1 · 工具與任務指示	已實作	有任務指示、實驗資料與推理工具
2 · 知識＋本次對話記憶	未實作	沒有資料檢索索引或對話知識設定
3 · 長期記憶＋推理	未實作	推理工具不等於跨對話記憶
4 · 多個 Agent 組隊合作	未實作	範例沒有組隊，也沒有互相分工
5 · 持續運作的 Agent 系統	未實作	終端機重試不等於持續運作的 Agent

LIKELY / SUGGESTED｜依指定文章與實際程式，判斷目前主要符合 Level 1。

第一版 Do New：Agent 讀資料，數值逐項核對

實際任務：比較 Final／Best 的梯度，並說清楚「跑完流程」與「駕駛品質」的差別。

summarize_p2_evidence() 讀入 144 筆紀錄／18 個樣本，由 Gemini 產生完整回答

評估 C：美國訓練、美國驗證、台灣各 6 筆，沿用 Teacher state 與原 loss。
本頁 loss 是 18 筆的中位數，與第 10 頁每輪平均、第 11 頁固定 120 筆平均不同。

已核對數值（整體中位數）	Final	Best
診斷 loss · 18 筆中位數	30.7705	29.9163
影像梯度 RMS	9.7748e−15	2.5796e−15
State 梯度 RMS	0.1907	0.2903
影像／state 梯度比值	6.7352e−14	2.2175e−14

已驗收回答的重點（依紀錄 §27 摘要，不是逐字引用）

回答列出的 8 個數值都與資料相符，也說明駕駛品質還沒驗證。

教授範例與我新增的 Do New 功能

比較面向	教授的基礎範例	我新增的 Do New
輸入與任務	目前啟用：旅行規劃問題	ModelB6 實驗結果與驗證影像
工具與證據	推理工具；尚未讀取本機實驗	讀取實驗資料，核對來源與檔案
結果呈現	文字／表格規劃回答	引用數據、描述影像，說明限制

三種模式：各自做什麼，驗證到哪裡

Diagnosis
分析 B6 資料，4 工具實測完成
本次報告已核對，引用已修正

Vision
讀取實際 PNG 描述可見內容
單張實測回答已驗收

Unified
結合數值與圖片，2 工具跑完
本次報告已核對，描述已修正

八個工具讀取實驗資料，也檢查資料來源

讀取模型資料 · 6 個工具

涵蓋訓練、四組影片驗證、輸入對照、Encoder、梯度與未訓練模型。

get_training_evidence / get_verification_evidence / get_sensitivity_evidence
get_encoder_evidence / get_gradient_evidence / get_fresh_gradient_evidence

比較影片與模型 · compare_domains

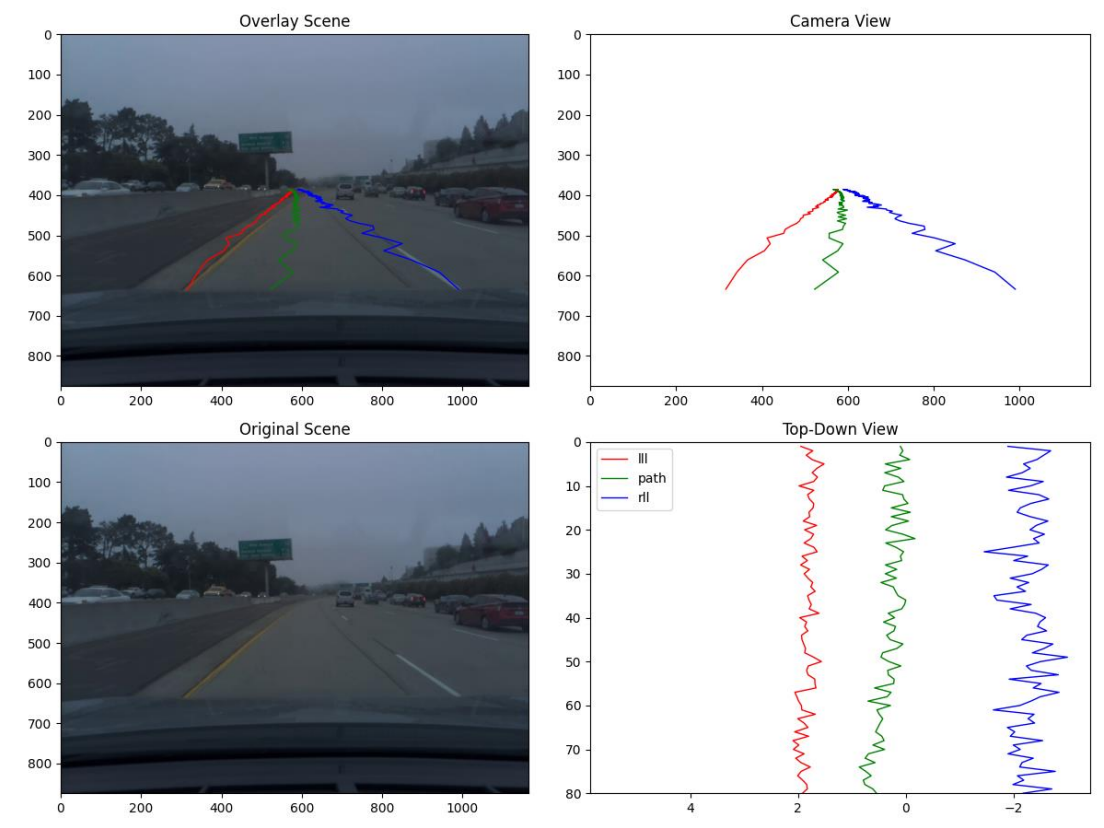
用相同條件，比較不同影片與模型版本。

檢查說法 · check_diagnostic_claim

依已整理的證據檢查說法；有資料支持，也不代表已找到唯一原因。

Vision 實測：給真實圖片，看 Agent 怎麼描述

輸入：B6 實際驗證圖片



USA／final／frame 1 · 1200 × 900 · hash 8c548903…

處理：將 PNG 檔案送給 Gemini

gemini-3.8-flash，輸出固定欄位報告
來源：使用者原始紀錄／§30

Agent 看到：路徑與車道線有鋸齒

“Severe high-frequency spatial oscillation / regression noise affecting the path and both lane line outputs simultaneously.”

前車對應：無法判斷（Unknown）

“no lead bounding box, tracking icon, or lead-specific overlay is rendered.”

限制：單張只能看空間形狀，不能確認移動情形、準確度、安全或唯一原因。

Diagnosis／Unified：給什麼資料，得到什麼回答

Diagnosis

輸入：B6 訓練、梯度與 Encoder 資料
指定工具：訓練、梯度、Encoder、說法檢查

實際回答（原文節錄）

“Validation deterioration is compatible with overfitting/instability, not a definitive cause”

loss 變差，還不能確定是過度擬合。

Unified

輸入：台灣 Best 第 1 幀＋數值資料
指定工具：影片驗證、compare_domains

實際回答（原文節錄）

“Whole-clip summary statistics such as lane_width_near_nonpositive_frames (0) describe aggregate behavior”

整段統計無法判定這張圖的誤差。

實測紀錄：Diagnosis 4 工具／29.301 秒，Unified 2 工具／6.857 秒；各跑 1 次、12 項檔案指紋吻合。

Agent 有跑完，不代表回答都正確

本機測試

96／96 項測試通過（先前紀錄）
檢查程式流程與錯誤處理

實際呼叫 API

檢查工具有回傳、報告有產生
檔案指紋吻合，只代表讀到同一份檔案

核對回答內容

人工對照數據、來源與圖片
逐項檢查模型的解讀

Agent	API 執行	內容
Baseline	已記錄	完整回答已核對
Evidence v1	已記錄	8 個數值已核對
Vision	PASS	單張已審核
Diagnosis	PASS	已核對／修正
Unified	PASS	已核對／修正

這三項分開驗證，不會自動一起通過。

Project 2：完成實作，也用實驗追查問題

01 完成課程要求

B6 訓練 60 epochs、四組 Step 6 驗證、Agno 範例與五層架構分析。

02 自己設計實驗，測試可能的修復方法

比較影像／state、Encoder 與梯度；兩種修復版本都未達到續訓條件。

03 讓 Agent 讀實驗資料，保留判斷來源

Evidence／Vision、Diagnosis／Unified 已實測，並加入來源、雜湊與路徑檢查。

我的做法：先用對照實驗縮小問題，再看結果決定要不要繼續訓練。

NOT VERIFIED｜駕駛品質、唯一原因、有效修復、自主選工具與跨樣本可靠度，仍未證實。
CONFIRMED｜Diagnosis／Unified 本次內容已核對並修正；驗證範圍限已測資料。